COMPUTER VISION

DETEKSI OBJEK KEPALA JANIN PADA CITRA ULTRASOUND

DISUSUN OLEH:

M. Rabyndra Janitra Binello (09021282328074)

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS SRIWIJAYA

2026

1. Dataset

1.1. Sumber Data

Dataset yang digunakan adalah Large-Scale Annotation Dataset for Fetal Head Biometry in Ultrasound Images yang tersedia dapat diakses melalui Zenodo (https://zenodo.org/records/8265464). Dataset ini terdiri citra ultrasound kepala janin yang telah dianotasi dengan bounding box untuk berbagai struktur anatomis.

Dari keseluruhan dataset, hanya subset plane trans-ventricular yang digunakan. Dua kelas target yang dipilih adalah:

a. CSP (Cavum Septi Pellucidi): Rongga di antara dua lamina septum pellucidum, terlihat sebagai struktur hiperekogenik di bagian anterior otak janin.
b. LV (Lateral Ventricle): Ventrikel lateral otak berisi cairan serebrospinal, terlihat sebagai area anekogenik pada citra USG.

1.2. Statistik Dataset

Keterangan	Jumlah
Total Gambar	584 Gambar
Total File Label	584 Label
Training Set (80%)	467 Gambar
Validation Set (20%)	117 Gambar
Total objek training (CSP + LV)	800 Objek
Total objek validasi (CSP + LV)	288 Objek

Distribusi kelas pada training set menunjukkan komposisi dari CSP 44.6% (357 objek) dan LV 55.4% (443 objek). Distribusi ini relatif seimbang sehingga tidak diperlukan penanganan class imbalance secara khusus.

2. Metodologi

2.1. Arsitektur Model

Model yang digunakan adalah YOLOv8n (You Only Look Once versi 8, varian nano) dari framework Ultralytics. YOLOv8 merupakan model object detection single-stage yang memproses gambar secara end-to-end dalam satu forward pass, menghasilkan prediksi bounding box dan kelas secara bersamaan.

Arsitektur YOLOv8n terdiri dari 130 layer dengan 3.011.238 parameter yang dapat dilatih. Varian nano dipilih karena efisiensi komputasi yang tinggi namun tetap memberikan performa kompetitif untuk dataset berukuran sedang. Model diinisialisasi dengan bobot pretrained dari dataset COCO (transfer learning), kemudian di-fine-tune pada dataset trans-ventricular.

2.2. Preprocessing dan Persiapan Data

a. Melakukan verifikasi dataset dengan memastikan setiap gambar memiliki file label yang sesuai (584 pasangan gambar-label terverifikasi tanpa missing file).
b. Melakukan train/validation split dataset dengan rasio 80:20, menghasilkan 467 gambar

c. Melakukan mapping ulang id class dari dataset yang menggunakan ID kelas 1 (CSP) dan 2 (LV). YOLOv8 mengharuskan class ID dimulai dari 0, sehingga dilakukan konversi class 1 ke 0 (CSP) dan class 2 ke 1 (LV). Class ID 0 pada dataset asli diabaikan karena bukan target deteksi.
d. Mengkonfigurasi data.yaml yang berisi path dataset, jumlah kelas (nc=2), dan nama kelas yang digunakan YOLOv8 selama training dan validasi.

2.3. Konfigurasi Pelatihan

Parameter	Nilai
Model base	YOLOv8n (pretrained COCO)
Epochs	100
Image size	640 x 640 piksel
Batch size	16
Early stopping (patience)	20 epoch
Optimizer	AdamW (auto-selected)
Learning rate awal	0.001667
Hardware	NVIDIA Tesla T4 (GPU)
Framework	Ultralytics 8.4.21, PyTorch 2.10.0+cu128

Augmentasi data diterapkan secara otomatis oleh Ultralytics selama training, meliputi mosaic augmentation, random horizontal flip, serta transformasi warna (HSV jitter).

Albumentations juga aktif dengan operasi Blur, MedianBlur, ToGray, dan CLAHE untuk meningkatkan ketahanan model terhadap variasi kualitas citra USG.

3. Hasil dan Analisis

3.1. Kurva Pelatihan

Model dilatih selama penuh 100 epoch tanpa early stopping, membutuhkan waktu sekitar 32 menit pada GPU Tesla T4. Gambar di bawah menunjukkan kurva training dan validasi selama proses pelatihan.

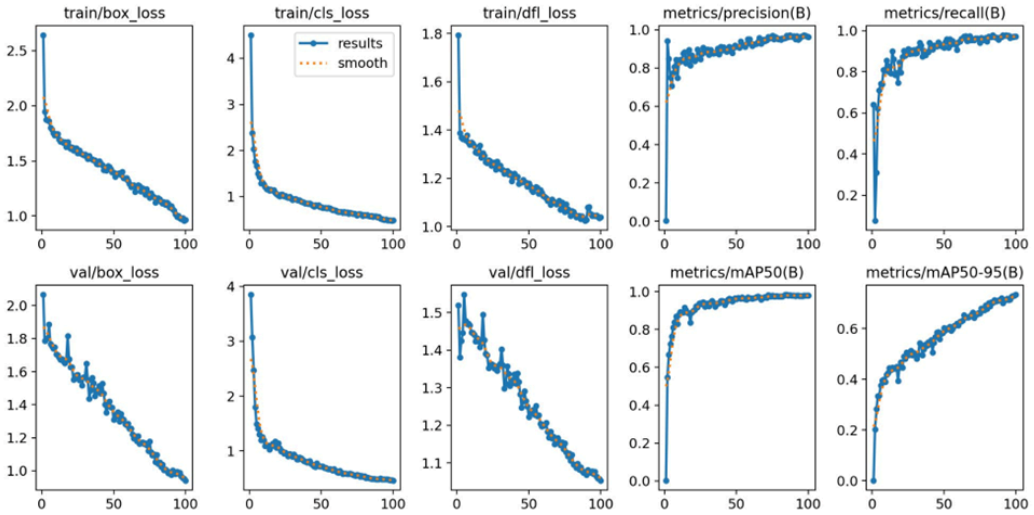

Proses pelatihan menunjukkan konvergensi yang stabil, dapat dilihat dari penurunan konsisten yang terjadi pada seluruh komponen loss seiring bertambahnya epoch. Training loss (box, cls, dfl) turun secara monoton dari epoch 1 hingga 100. Validation loss mengikuti pola yang sama meski dengan fluktuasi yang lebih terlihat pada epoch awal, menandakan model belajar secara generalisatif tanpa adanya overfitting.

Metrik Precision dan Recall sama-sama meningkat pesat pada 20 epoch pertama, kemudian melandai secara bertahap mendekati nilai optimal di atas 0.96. mAP@0.5 mencapai nilai di atas 0.95 sejak sekitar epoch 40 dan terus meningkat mendekati 0.98 di akhir training. mAP@0.5:0.95 juga menunjukkan tren naik yang konsisten hingga mencapai sekitar 0.73.

3.2. Metrik Evaluasi

Evaluasi dilakukan pada validation set menggunakan bobot terbaik (best.pt) yang dipilih berdasarkan mAP@0.5 tertinggi selama training. Hasil evaluasi keseluruhan:

Metrik	**Nilai**
mAP@0.5	0.9795
mAP@0.5:0.95	0.7333
Precision	0.9610
Recall	0.9727

Hasil per kelas menunjukkan performa yang konsisten antara CSP dan LV:

Kelas	mAP@0.5	Precision	Recall
CSP	0.9690	0.9580	0.9760
LV	0.9900	0.9640	0.9690

3.3. Confusion Matrix

Gambar di bawah menunjukkan confusion matrix hasil validasi model pada validation set.

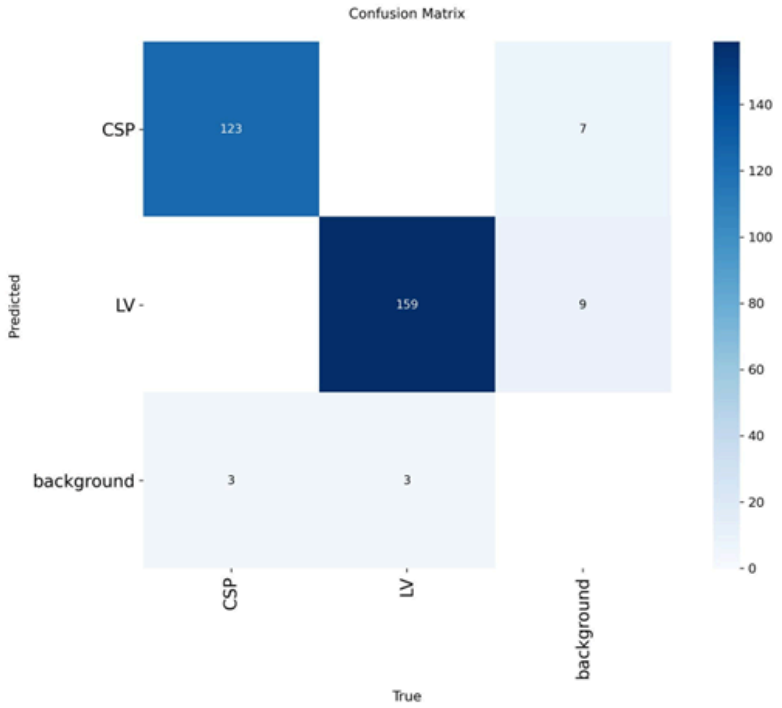

Confusion matrix menunjukkan distribusi prediksi sebagai berikut:

a. CSP terdeteksi dengan benar (true positive): 123 dari 130 objek (94.6%)
b. LV terdeteksi dengan benar (true positive): 159 dari 168 objek (94.6%)
c. CSP gagal terdeteksi sebagai background (false negative): 7 objek
d. LV gagal terdeteksi sebagai background (false negative): 9 objek

e. Background salah diprediksi sebagai CSP (false positive): 3 kasus
f. Background salah diprediksi sebagai LV (false positive): 3 kasus

Temuan paling utama adalah tidak terdapat confusion antar kelas model yang tidak pernah salah memprediksi CSP sebagai LV atau sebaliknya. Seluruh kesalahan terjadi antara objek dengan background, yang merupakan tipe kesalahan yang lebih dapat diterima secara klinis.

3.4. Visualisasi Hasil Deteksi

Gambar di bawah menampilkan hasil deteksi bounding box pada 6 sampel gambar validasi yang dipilih secara acak. Bounding box biru merepresentasikan deteksi CSP, sedangkan bounding box cyan merepresentasikan deteksi LV, masing-masing disertai nilai confidence score.

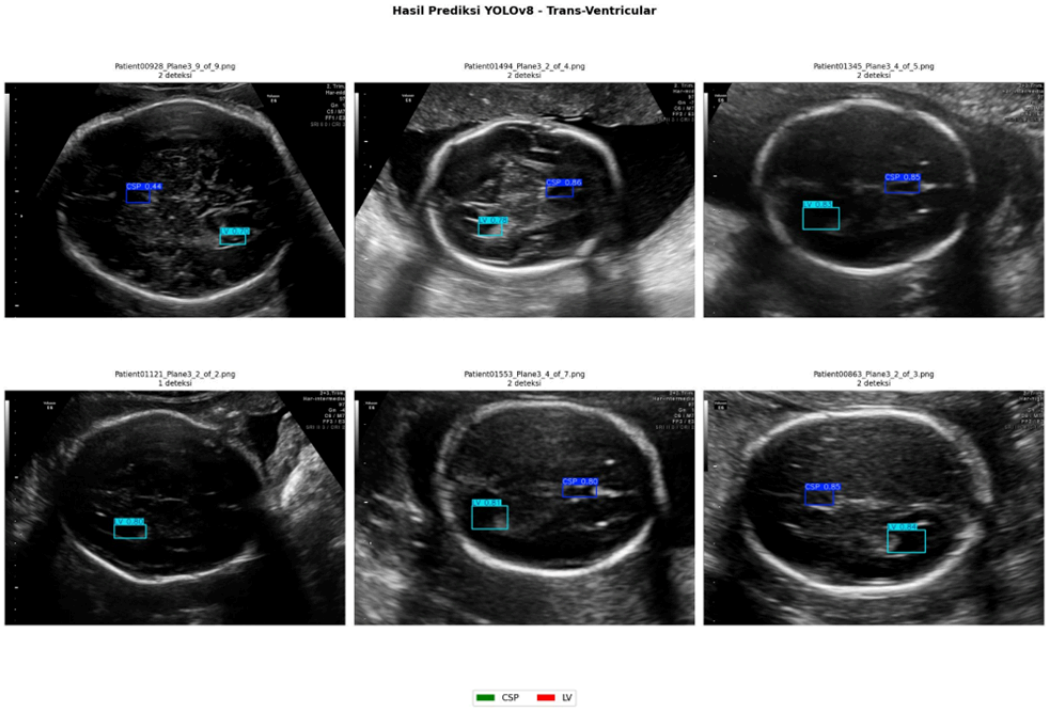

Dari 6 sampel yang ditampilkan, 5 gambar berhasil mendeteksi 2 objek (CSP dan LV) secara bersamaan, sedangkan 1 gambar hanya mendeteksi 1 objek (LV). Confidence score deteksi berkisar antara 0.44 hingga 0.86. Kasus dengan confidence rendah (CSP 0.44 pada gambar pertama) berkorelasi dengan kondisi citra USG yang lebih noise dan posisi CSP yang kurang jelas secara visual.

3.5. Analisis Performa

Nilai mAP@0.5 sebesar 0.9795 menandakan bahwa model berhasil mendeteksi lebih dari 97% objek CSP dan LV dengan akurasi lokalisasi yang baik dengan threshold IoU 0.5. Precision 0.961 dan Recall 0.9727 yang sama-sama tinggi menandakan keseimbangan antara minimnya false positive dan false negative.

Perbedaan antara mAP@0.5 (0.9795) dan mAP@0.5:0.95 (0.7333) menunjukkan bahwa meskipun model sangat akurat dalam mendeteksi keberadaan objek, masih terdapat ruang untuk meningkatkan kualitas presisi lokalisasi bounding box pada threshold IoU yang lebih ketat. Hal ini wajar karena model yang digunakan adalah varian nano (YOLOv8n) yang diprioritaskan untuk efisiensi komputasi.

Kelas LV mencatat mAP@0.5 sedikit lebih tinggi (0.990) dibandingkan dengan CSP (0.969). Hal ini kemungkinan disebabkan ukuran LV yang umumnya lebih besar pada citra USG sehingga lebih mudah dilokalisasi, sementara CSP

merupakan struktur yang lebih kecil dan memerlukan presisi lokalisasi yang lebih tinggi.

4. Kesimpulan

Model YOLOv8n yang dilatih pada dataset trans-ventricular berhasil mendeteksi struktur CSP dan LV pada citra ultrasound kepala janin dengan performa yang sangat baik. Nilai mAP@0.5 sebesar 0.9795 dengan Precision 0.961 dan Recall 0.9727 menunjukkan bahwa model dapat mendeteksi hampir seluruh objek dengan akurasi tinggi dan tingkat false positive yang rendah.

Dengan ini dapat disimpulkan:

a. Transfer learning dari pretrained COCO terbukti efektif meskipun domain citra USG sangat berbeda dari natural image pada COCO.
b. Distribusi kelas yang relatif seimbang berpengaruh pada performa yang merata di kedua kelas tanpa penanganan class imbalance.
c. Tidak adanya confusion antar kelas (CSP vs LV) mengindikasikan model berhasil mempelajari fitur visual yang membedakan kedua struktur anatomis tersebut.
d. Seluruh kesalahan prediksi terjadi terhadap background, bukan antar kelas, yang merupakan karakteristik yang lebih aman secara klinis.

5. Referensi

a. Burgos-Artizzu, X.P., et al. (2023). Large-Scale Annotation Dataset for Fetal Head Biometry in Ultrasound Images. Zenodo. https://zenodo.org/records/8265464
b. Jocher, G., et al. (2023). Ultralytics YOLOv8. https://docs.ultralytics.com/
c. Burgos-Artizzu, X.P., et al. (2023). Analysis of Fetal Head Biometry in Ultrasound. ScienceDirect. https://www.sciencedirect.com/article/pii/S2352340923007837
d. IEEE Xplore (2024). https://ieeexplore.ieee.org/document/10480532